

Classification multi-classe des types de cancer du foie par une approche radiomique

Big data & Santé

Données issues de l'Hôpital Henri-Mondor AP-HP

Antonin RICOCHON | Mathéo CAHITTE | Yann MOUSSU | Ilias BOURHRARA
Clément COURNIL-RABEUX

Résumé

Ce rapport présente la conception et l'évaluation de modèles de classification automatique pour trois types de tumeurs hépatiques : le Carcinome Hépatocellulaire (CHC), le Cholangiocarcinome (CCK), et les tumeurs de forme mixte. À partir d'un jeu de données cliniques et radiomiques hautement dimensionnel fourni par l'Hôpital Henri-Mondor (AP-HP), nous développons des pipelines de prétraitement, de normalisation hybride et de sélection de caractéristiques (LASSO, ElasticNet). Face aux performances exceptionnelles mais dépendantes d'une notation humaine des données des radiologues, nous introduisons une méthodologie innovante de création de *pseudo-features radiologiques composites*, optimisées par régressions intermédiaires, établissant un pont interprétable entre la radiomique quantitative et la sémiologie médicale.

[Lien vers le dépôt GitHub](#)



CentraleSupélec

Table des matières

1	Introduction et objectifs	3
2	Traitement des données	3
2.1	Prétraitement des données	3
2.2	Normalisation du jeu de données	4
2.3	Méthode des deltas	4
3	Sélection des features et choix du modèle	5
3.1	Méthode d'évaluation des modèles : validation croisée	5
3.2	Comparaison des méthodes sur données radiomiques	5
3.3	Approche par décorrélation des caractéristiques	6
3.4	Stratégie des pseudo-features radiologiques composites	8
3.4.1	Comparaison entre données radiologiques et données radiomiques	8
3.4.2	Construction de features composites	10
4	Analyse des résultats	12
4.1	Application des modèles sur la classe Mixtes	12
4.2	Récapitulatif des résultats des features pseudo-équivalentes	12
5	Conclusion	13

1 Introduction et objectifs

Le carcinome hépatocellulaire (CHC) et le cholangiocarcinome (CCK) représentent les formes les plus prévalentes de cancers primitifs du foie, présentant des prises en charge cliniques et des pronostics radicalement différents. Les formes composites, dites tumeurs mixtes, complexifient davantage le diagnostic différentiel. L'identification précise et non invasive de ces phénotypes tumoraux par imagerie médicale est un enjeu crucial en oncologie hépatique.

L'objectif principal de ce projet est de développer et de valider rigoureusement un modèle prédictif capable de classer ces 3 types de cancers du foie (Figure 1) en exploitant des données issues de l'Hôpital Henri-Mondor AP-HP. Le défi technique repose sur l'exploitation de descripteurs radiomiques extraits d'examens IRM, caractérisés par une forte dimensionnalité et une redondance structurelle, tout en essayant de préserver une interprétabilité clinique forte.




FIGURE 1 – IRM des trois types de tumeurs étudiées : CHC, CCK et Mixte.

2 Traitement des données

2.1 Prétraitement des données

Le jeu de données initial est séparé en plusieurs tables : des données descriptives de base (`Descriptif_patients.csv`), des données radiologiques établies par le diagnostic de radiologues (`Relectures_imageries.csv`), des données radiomiques simples (`global_excel_resampled.csv`) et des données radiomiques multi-phases et multi-coupes (`multislice.csv`). La première étape a consisté à enrichir la base radiomique principale par l'intégration de variables cliniques fondamentales : l'âge et le sexe du patient.

Un nettoyage rigoureux a été appliqué sur les phases d'acquisition de l'imagerie. Les données ont subi un filtrage strict selon le nombre de phases disponibles par patient afin de garantir la consistance des descripteurs temporels de rehaussement (Figure 2).




FIGURE 2 – Impact du filtrage par nombre de phases sur la distribution du jeu de données.

Pour rendre exploitables les matrices tridimensionnelles issues de l'extraction de caractéristiques sur plusieurs coupes, deux stratégies ont été appliquées :

1. **Flattening (Aplatissement)** : Transformation de la structure multi-dimensionnelle en un vecteur de caractéristiques à plat unique par patient.
2. **Réduction de la dimensionnalité pour multi-slices** : agrégation statistique visant à compacter l'information spatiale redondante des différentes coupes en une représentation robuste unique (Figure 3).




FIGURE 3 – Méthode employée pour rendre les données multislice exploitables.

2.2 Normalisation du jeu de données

Considérant que la radiomique extrait des variables d'ordres de grandeurs hétérogènes (intensité, géométrie, texture), la normalisation est indispensable. Nous avons mis en concurrence deux stratégies majeures (Figure ??) :

1. **Normalisation Standard** : Ajustement indépendant de chaque variable en lui appliquant sa propre moyenne μ_i et son écart-type σ_i .
2. **Normalisation Hybride** : Regroupement des variables de type *first_order* qui partagent un lien physique intrinsèque direct lié aux unités de l'appareil d'imagerie. Elles subissent une normalisation conjointe via un canal commun utilisant les mêmes statistiques globales (μ, σ), évitant ainsi de déformer artificiellement les rapports d'intensités inter-phases. Les autres descripteurs (de forme ou de texture) conservent un traitement standard centré-réduit classique.

2.3 Méthode des deltas

Pour approfondir la dynamique temporelle du rehaussement de contraste entre les phases injectées, un traitement fondé sur le calcul des deltas inter-phases a été introduit (Figure 4). Les données Deltas ne seront pas significatives lors de la sélection des features.




FIGURE 4 – Méthode employée pour exploiter la cinétique de la tumeur

3 Sélection des features et choix du modèle

3.1 Méthode d'évaluation des modèles : validation croisée

Pour prémunir nos modèles du surapprentissage (*overfitting*) induit par la forte dimensionnalité, nous avons implémenté une validation croisée à $K = 5$ plis (*5-Fold Cross-Validation*).

L'évaluation prend soin de surveiller la répartition des variables sensibles et démographiques à travers les différents plis d'évaluation pour en valider l'équilibre homogène (Figure 5).




FIGURE 5 – Proportions et équilibre des variables sensibles au sein des plis de validation.

3.2 Comparaison des méthodes sur données radiomiques

Une recherche par grille (*Grid Search*) exhaustive a été menée pour optimiser conjointement les hyperparamètres de des modèles ElasticNet et les jeux de données à utiliser (Figure 6).




FIGURE 6 – Grid search ElasticNet : F1-score par Dataset et par Hyperparamètres.

Cette Grid Search révèle que les meilleurs scores F1 sont obtenus sur le jeu de données radiomiques globales, et pour une pénalisation ElasticNet essentiellement LASSO. En se focalisant sur le modèle LASSO appliqué aux données radiomiques brutes standardisées, on obtient les performances présentées sur la Figure 7.




FIGURE 7 – Accuracy et F1 du modèle Lasso sur la validation croisée des données radiomiques.

Pour une valeur de paramètre d'inversion de régularisation $C = 0.5$, la pénalisation du LASSO force l'annulation de la majorité des coefficients, sélectionnant un sous-ensemble parcimonieux de 16 caractéristiques majeures listées dans le Tableau 1. On observe par exemple l'importance de la sphéricité de la phase portale (**shape_Sphericity_PORT**) ainsi que le maintien de la variable démographique du genre (**Gender**).

TABLE 1 – Features sélectionnées par le Modèle Lasso avec $C = 0.5$ (16 features) sur le dataset original.

Feature	Coefficient
shape_Sphericity_PORT	0.845447
gldm_DependenceVariance_PORT	0.534582
firstorder_Skewness_PORT	0.516820
Gender	0.235438
glszm_SmallAreaLowGrayLevelEmphasis_ART	0.234221
glrlm_GrayLevelNonUniformity_ART	0.228108
ngtdm_Busyness_ART	0.203912
gldm_DependenceVariance_ART	0.202661
gldm_SmallDependenceLowGrayLevelEmphasis_TARD	-0.199737
firstorder_Minimum_PORT	0.137959
glszm_GrayLevelNonUniformity_ART	0.082482
shape_Sphericity_TARD	0.065516
shape_Flatness_ART	-0.057079
ngtdm_Coarseness_TARD	0.049743
firstorder_Skewness_ART	0.042475
shape_Flatness_PORT	-0.041216

3.3 Approche par décorrélation des caractéristiques

Un examen visuel de la matrice de corrélation globale (Figure 8) révèle des blocs de forte redondance colinéaire entre les descripteurs texturaux calculés sur différentes phases.



FIGURE 8 – Clustermap illustrant la redondance et la forte corrélation des features.

Afin d'épurer l'espace de description, nous appliquons un algorithme de filtrage basé sur la méthode de décorrélation suivante :

1. **Valeurs absolues** : On traite uniformément les corrélations négatives ($r = -0.9$ est équivalent à $r = 0.9$).
2. **Triangle supérieur** : On ne compare chaque paire qu'une seule fois en excluant la diagonale.
3. **Seuil $\tau = 0.9$** : Suppression systématique de la feature redondante.

Ce processus d'élagage agressif a conduit à des résultats de nettoyage massifs, réduisant la taille du problème de manière drastique sans perte d'information majeure en passant de 320 features initiales à 70 features conservées.

L'entraînement du modèle Lasso sur cette base décorrélée (Figure 9) permet d'isoler à nouveau 16 caractéristiques clés à $C = 0.3$, détaillées dans le Tableau 2.




FIGURE 9 – Accuracy et F1 du modèle Lasso sur les features décorréliées (< 0.9).

TABLE 2 – Features sélectionnées par le Modèle Lasso avec $C = 0.3$ sur le dataset décorrélé.

Feature	Coefficient
shape_Sphericity_PORT	0.907565
ngtdm_Busyness_ART	0.595096
firstorder_Skewness_PORT	0.530377
glrlm_RunLengthNonUniformityNormalized_PORT	-0.361344
Gender	0.301239
gldm_SmallDependenceLowGrayLevelEmphasis_TARD	-0.233911
shape_Flatness_ART	-0.102125
glszm_SmallAreaLowGrayLevelEmphasis_PORT	0.086747
ngtdm_Coarseness_TARD	0.086139
shape_Flatness_PORT	-0.083689
shape_SurfaceVolumeRatio_PORT	-0.081185
firstorder_InterquartileRange_PORT	-0.073187
shape_Sphericity_TARD	0.047352
firstorder_Skewness_ART	0.030737
glrlm_RunLengthNonUniformity_PORT	0.028465
glcm_Idn_PORT	0.000515

La comparaison directe des features principales identifiées par les deux approches fait l'objet d'un alignement graphique afin de cartographier la stabilité des descripteurs phares (Figure 10).




FIGURE 10 – Matching des features principales entre les deux méthodes de sélection.

3.4 Stratégie des pseudo-features radiologiques composites

3.4.1 Comparaison entre données radiologiques et données radiomiques

L'un des constats majeurs de l'étude réside dans le fossé de performance observé entre l'exploitation brute des données radiomiques (`global` et `multislice`) et des données radiologiques de `Relectures_imageries.csv`. L'analyse en composantes principales (ACP) sur les pures annotations des radiologues montre une séparation spatiale quasi-parfaite (Figure 11).




FIGURE 11 – Analyse en composantes principales sur les données de `Relectures_imageries.csv`

L'évaluation d'un modèle LASSO (avec $C = 0.5$) alimenté par ces données livre des scores remarquables (Figure 12).




FIGURE 12 – Résultats et matrice de confusion obtenus avec un LASSO sur les données radiologiques

Dans l'objectif de construire à l'aide des données radiomiques un modèle similaire au `modele_radiologue`, nous avons établi des corrélations entre les données radiomiques et les données sémiologiques des radiologues. Nous utilisons deux critères pour établir les features radiomiques corrélées avec les données radiologiques : la p -value et l'AUC-ROC (Figure 13) et traçons une heatmap d'association globale (Figure 14).




FIGURE 13 – Courbe de $-\log(\text{p-value})$ en fonction de l'AUC-ROC

L'**AUC-ROC** (aire sous la courbe ROC) est la probabilité qu'une feature radiomique classe correctement deux patients tirés au hasard et présentant des modalités opposées de la feature radiologique. Le critère appliqué est : $|\text{AUC-ROC} - 0.5| \geq 0.15$.

La **p-value**, portant sur les hypothèses $\mathcal{H}_0$ (absence d'association significative entre la caractéristique radiomique et le critère radiologique) et $\mathcal{H}_1$ (présence d'une corrélation significative entre la caractéristique radiomique et le critère radiologique), a un seuil de rejet $\alpha = 0.05$.




FIGURE 14 – Heatmap associant les features sémiologiques à 3 features radiomiques

3.4.2 Construction de features composites

L'idée consiste à imiter les critères sémiologiques des radiologues en construisant des **pseudo-features radiologiques composites** par combinaison linéaire de features radiomiques :

$$\text{pseudo_F} = w_1 \cdot \text{F_1} + w_2 \cdot \text{F_2} + w_3 \cdot \text{F_3} + \beta_0$$

Trois approches ont été testées pour établir un modèle à partir de ces pseudo-features :

1^{ère} approche (Poids par corrélation directe) : Les poids w_n correspondent aux coefficients extraits de la matrice de corrélation. Les résultats associés à l'utilisation de ces variables composites via une régression RIDGE donnent les scores présentés sur la Figure 15.




FIGURE 15 – Analyse en composantes principales (ACP) et régression RIDGE avec features composites (première approche).

2^{ème} approche avec régression LASSO : Les features composites définies ci-dessus sont injectées conjointement avec le reste des features radiomiques puis sélectionnées par une régression LASSO avec $C = 0.5$ (Figure 16).




FIGURE 16 – ACP et LASSO ($C = 0.5$) combinant features composites et radiomiques originales.

3^{ème} approche avec poids optimisés : L'objectif est ici d'optimiser finement les pondérations w_n et la constante β_0 pour chaque critère clinique via un pré-apprentissage dédié :

1. **Appariement** : Sélection de 2 à 3 features radiomiques fortement associées pour chaque critère clinique.
2. **Apprentissage par variable cible** :
 - Variable catégorielle (*Diffusion_targetoid*, *Capsule*, etc.) → **Régression Logistique**.
 - Variable continue (*Size*) → **Régression Linéaire**.
3. **Extraction** : Utilisation directe des coefficients du modèle comme poids w_n .

L'optimisation globale montre une nette convergence des performances (Figure 17).




FIGURE 17 – Résultats de l'optimisation des poids

L'évaluation de ce pipeline final combinant poids optimisés et régression LASSO avec $C = 0.5$ livre de très bons scores, se rapprochant de la performance du `modele_radiologue` (Figure 18).



FIGURE 18 – LASSO appliqué sur features composites à poids optimisés + radiomiques.

L'analyse de l'importance des variables au sein de ce modèle montre la prédominance de la composante émulant le comportement de rehaussement tardif (*Late_enhancement*), explicitée par les magnitudes de la Figure 19.




FIGURE 19 – Variables prépondérantes et magnitudes sélectionnées par le LASSO final.

4 Analyse des résultats

4.1 Application des modèles sur la classe Mixtes

La classe des tumeurs composites/mixtes pose un défi conceptuel majeur car elle ne dispose pas d’une identité phénotypique unique, oscillant entre le CHC et le CCK. Nous avons appliqué notre meilleur classifieur sur ces échantillons afin d’analyser la répartition de la prédiction douce (*soft probabilities*) (Figure 20).




FIGURE 20 – Distribution de la prédiction douce entre les pôles CCK et CHC pour la classe Mixte.

L’évaluation du modèle sur les tumeurs mixtes (Figure 13) offre une perspective nuancée face à la classification visuelle (LI-RADS). Alors que l’œil humain a tendance à forcer un diagnostic binaire, l’algorithme place une grande partie de ses prédictions autour de 50 % de probabilité ($p \approx 0.5$), traduisant mathématiquement la double nature de ces cancers. Cette cohérence se confirme sur le sous-groupe des tumeurs mixtes classées LR-5 (visuellement dominées par un aspect CHC) : le modèle leur attribue logiquement une forte probabilité d’être un CHC (autour de 0,85). Il valide ainsi l’observation du radiologue sur la composante majoritaire, tout en conservant une marge d’incertitude (15 %) qui rappelle qu’il ne s’agit pas d’un CHC parfaitement pur.

4.2 Récapitulatif des résultats des features pseudo-équivalentes

Le Tableau 3 dresse le bilan comparatif complet de l’ensemble des architectures de modèles développées au cours de ce projet.

Modèle	Accuracy	ROC AUC	F1-Score	MCC
Radiomiques globales, LASSO	0.854 ± 0.050	0.823 ± 0.112	0.729 ± 0.096	0.491 ± 0.197
Données radiologiques, LASSO	0.985 ± 0.030	0.999 ± 0.002	0.983 ± 0.035	0.965 ± 0.069
Poids par corrélation, RIDGE, global	0.797 ± 0.095	0.878 ± 0.064	0.710 ± 0.111	0.475 ± 0.223
Poids par corrélation, LASSO, global	0.830 ± 0.033	0.845 ± 0.064	0.744 ± 0.041	0.530 ± 0.092
Poids optimisés, RIDGE, global	0.818 ± 0.081	0.848 ± 0.071	0.737 ± 0.103	0.523 ± 0.205
Poids optimisés, LASSO, global	0.853 ± 0.043	0.819 ± 0.067	0.777 ± 0.062	0.602 ± 0.118
Poids optimisés, LASSO, multislice	0.835 ± 0.079	0.821 ± 0.102	0.780 ± 0.097	0.579 ± 0.178

TABLE 3 – Comparaison des performances globales des modèles de pseudo-features.

5 Conclusion

Ce projet a permis de structurer un pipeline rigoureux de traitement de données d'imagerie hépatique quantitative provenant de l'Hôpital Henri-Mondor. L'introduction de descripteurs pseudo-sémiologiques à poids optimisés offre une avancée décisive en matière d'interprétabilité des décisions pour les cliniciens.