



Classification des types de cancer du foie

Yann MOUSSU
Mathéo CAHITTE
Ilias BOURHRARA
Antonin RICOCHON
Clément COURNIL-RABEUX



Objectif

Objectif : Développer un modèle de classification de 3 types de cancer du foie à partir de données issues de l'Hôpital Henri-Mondor AP-HP.



(a) Type CHC

(b) Type CCK

(c) Type mixte

Figure 1 - IRM des 3 types de tumeur : CHC, CCK et Mixte


Plan

- ① Traitement des données
 - Prétraitement des données
 - Normalisation du jeu de données
- ② Sélection des features et choix du modèle
 - Méthode d'évaluation des modèles : validation croisée
 - Comparaison des méthodes
 - Stratégie des pseudo-features radiologiques
- ③ Analyse des résultats
 - Application des modèles sur la classe Mixtes
 - Comparaison des résultats des features pseudo-équivalentes
- ④ Conclusion et perspectives

Plan

- ① Traitement des données
 - Prétraitement des données
 - Normalisation du jeu de données
- ② Sélection des features et choix du modèle
- ③ Analyse des résultats
- ④ Conclusion et perspectives


Ajout des colonnes âge et sexe




Filtrage par nombre de phase

Proportions avant et après la sélection des patients ayant 3 phases mesurées


Sexe
Avec tous les patients




Type de Cancer
Avec tous les patients




Tranche d'âge
Avec tous les patients




Sexe
Avec les patients ayant 3 phases mesurées



Type de Cancer
Avec les patients ayant 3 phases mesurées



Tranche d'âge
Avec les patients ayant 3 phases mesurées



Flattening




Figure 2 - Schéma illustrant l'aplatissement des données

Réduction de la dimensionnalité pour multi-slices




Figure 3 - Méthode employée pour rendre les données multislice exploitables

Stratégies de normalisation




Figure 4 - Méthode employée pour normaliser les données

Plan

- ① Traitement des données
- ② Sélection des features et choix du modèle
 - Méthode d'évaluation des modèles : validation croisée
 - Comparaison des méthodes
 - Stratégie des pseudo-features radiologiques
- ③ Analyse des résultats
- ④ Conclusion et perspectives

Plan

- ① Traitement des données
- ② Sélection des features et choix du modèle
 - Méthode d'évaluation des modèles : validation croisée
 - Comparaison des méthodes
 - Stratégie des pseudo-features radiologiques
- ③ Analyse des résultats
- ④ Conclusion et perspectives

Méthode d'évaluation des modèles : validation croisée

Fold 1 :	Test 1	Train	Train	Train	Train
Fold 2 :	Train	Test 2	Train	Train	Train
Fold 3 :	Train	Train	Test 3	Train	Train
Fold 4 :	Train	Train	Train	Test 4	Train
Fold 5 :	Train	Train	Train	Train	Test 5

Figure 5 - Validation croisée (k fold)

Méthode d'évaluation des modèles : validation croisée




Figure 6 - Proportions des variables sensibles

Plan

- ① Traitement des données
- ② Sélection des features et choix du modèle
 - Méthode d'évaluation des modèles : validation croisée
 - Comparaison des méthodes
 - Stratégie des pseudo-features radiologiques
- ③ Analyse des résultats
- ④ Conclusion et perspectives

Comparaison des méthodes




Figure 7 - Grid search ElasticNet : F1-score par Dataset et par Hyperparamètres

Méthode sur les données radiomiques

Modèle Lasso sur les données radiomiques standardisées




Figure 8 - Accuracy et F1 du modèle Lasso sur la validation croisée

Features sélectionnées sur le dataset original

Features sélectionnés par le Modèle Lasso avec $C = 0.5$ (16 features)

Feature	Coefficient
shape_Sphericity_PORT	0.845447
gldm_DependenceVariance_PORT	0.534582
firstorder_Skewness_PORT	0.516820
Gender	0.235438
glszm_SmallAreaLowGrayLevelEmphasis_ART	0.234221
glrlm_GrayLevelNonUniformity_ART	0.228108
ngtdm_Busyness_ART	0.203912
gldm_DependenceVariance_ART	0.202661
gldm_SmallDependenceLowGrayLevelEmphasis_TARD	-0.199737
firstorder_Minimum_PORT	0.137959
glszm_GrayLevelNonUniformity_ART	0.082482
shape_Sphericity_TARD	0.065516
shape_Flatness_ART	-0.057079
ngtdm_Coarseness_TARD	0.049743
firstorder_Skewness_ART	0.042475
shape_Flatness_PORT	-0.041216

Méthodes avec les features décorélées




Figure 9 - Clustermap des features

Méthode de décorrélation

Algorithme appliqué :

- ① **Valeurs absolues** : On traite $r = -0.9$ comme $r = 0.9$.
- ② **Triangle supérieur** : On ne compare chaque paire qu'une seule fois.
- ③ **Seuil** $\tau = 0.9$: Suppression de la feature redondante.

Résultats du nettoyage

- Features initiales : 320
- Features supprimées : 250
- **Features conservées : 70**

Modèle Lasso sur les features décorrélées




Figure 10 - Accuracy et F1 du modèle Lasso sur les features décorrélées (< 0.9)


Features sélectionnées sur le dataset décorrélé

Features sélectionnés par le Modèle Lasso avec $C = 0.3$ (16 features)

Feature	Coefficient
shape_Sphericity_PORT	0.907565
ngtdm_Busyness_ART	0.595096
firstorder_Skewness_PORT	0.5303770
glrlm_RunLengthNonUniformityNormalized_PORT	-0.361344
Gender	0.301239
gldm_SmallDependenceLowGrayLevelEmphasis_TARD	-0.233911
shape_Flatness_ART	-0.102125
glszm_SmallAreaLowGrayLevelEmphasis_PORT	0.086747
ngtdm_Coarseness_TARD	0.086139
shape_Flatness_PORT	-0.083689
shape_SurfaceVolumeRatio_PORT	-0.081185
firstorder_InterquartileRange_PORT	-0.073187
shape_Sphericity_TARD	0.047352
firstorder_Skewness_ART	0.030737
glrlm_RunLengthNonUniformity_PORT	0.028465
glcm_Idn_PORT	0.000515

Comparaison des deux méthodes

Matching des features principales entre les 2 méthodes



Plan

- ① Traitement des données
- ② Sélection des features et choix du modèle
 - Méthode d'évaluation des modèles : validation croisée
 - Comparaison des méthodes
 - Stratégie des pseudo-features radiologiques
- ③ Analyse des résultats
- ④ Conclusion et perspectives

Motivations





Figure 11 - Analyse en composantes principales sur les données radiologiques

Performance du dataset des radiologues




Métrique	Valeur
Accuracy	0.985 ($\pm$ 0.030)
ROC AUC	0.999 ($\pm$ 0.002)
F1-Score	0.983 ($\pm$ 0.035)

Figure 12 - Résultats obtenus avec un lasso sur les données radiologiques

Comparaison données radiologiques VS radiomiques

Idée : établir des corrélations données radiologiques - radiomiques



Métrique AUC-ROC :

- Probabilité qu'une feature radiomique classe correctement deux patients avec une feature radiologique opposée
- Critère $|AUC-ROC - 0.5| \geq 0.15$

Significativité (p-value) :

- Seuil de rejet $\alpha = 0.05$

Figure 13 - Courbe de $-\log(p\text{-value})$ en fonction de AUC-ROC

Comparaison données radiologiques VS radiomiques




Figure 14 - Heatmap de l'AUC ROC (équivalent radiologiques-radiomiques)

Un exemple : la feature capsule




Figure 15 - Corrélation des features radiomiques avec la feature Capsule

Une première approche des features pseudo-sémiologiques

Idée : Imiter les critères sémiologiques des radiologues en construisant des **pseudo-features radiologiques composites** par combinaison linéaire de caractéristiques radiomiques.

Construction d'une pseudo-feature composite


$$\text{pseudo_F} = w_1 \cdot \text{F_1} + w_2 \cdot \text{F_2} + w_3 \cdot \text{F_3} + \beta_0$$

1^{re} **approche** : poids w_n = coefficients de la matrice de corrélation

Par exemple,

$$\begin{aligned} \text{Capsule} = & 0.6525 \cdot \text{Sphericity_TARD} + 0.1072 \cdot \text{Sphericity_PORT} \\ & + 0.1336 \cdot \text{Flatness_TARD} - 0.2924 \end{aligned}$$

Résultats pour la première approche




	CCK	
	11	12
CHC	6	59
	CCK	CHC

Accuracy	0.797 ± 0.095
ROC AUC	0.878 ± 0.064
F1-Score	0.710 ± 0.111

Figure 16 - ACP et régression RIDGE avec features composites

Deuxième approche avec régression LASSO



		type	
		CCK	CHC
	CCK	11	12
	CHC	3	62
		CCK	CHC

Accuracy	0.830 ± 0.033
ROC AUC	0.845 ± 0.064
F1-Score	0.744 ± 0.041

Figure 17 - ACP et LASSO ($C = 0.5$) avec features composites + radiomiques

Troisième approche avec poids optimisés

Objectif : Optimiser les pondérations w_n et la constante β_0 pour chaque pseudo-feature radiologique.

- ① **Appariement :** Sélection de 2 à 3 features radiomiques fortement corrélées pour chaque critère clinique.
- ② **Apprentissage par variable cible :**
 - Variable catégorielle (Diffusion_targetoid, Capsule, etc) → **Régression Logistique**
 - Variable continue (Size) → **Régression Linéaire**
- ③ **Extraction :** Utilisation des coefficients du modèle comme poids w_n pour l'équation composite.

Résultat de l'optimisation




Figure 18 - Résultats de l'optimisation des poids

Résultats du Lasso avec les poids optimisés

CCK	12	11
CHC	2	63
	CCK	CHC

- Régression LASSO ($C = 0,5$)
- Poids w_n déterminés par régression
- Optimisation de l'accuracy

Accuracy	0.853 ± 0.043
ROC AUC	0.849 ± 0.067
F1-Score	0.777 ± 0.062

Figure 19 - LASSO, features composites à poids optimisés + radiomiques

Features prépondérantes dans le LASSO




Figure 20 - Variables prépondérantes sélectionnées par LASSO


$$\text{Late_enhancement} = -0.9865 + \text{LDHGLEmphasis_TARD} * 1.3069 + \text{LRHGLEmphasis_TARD} * (-0.8183) + \text{SALGLEmphasis_ART} * (-0.4796)$$

Plan

- ① Traitement des données
- ② Sélection des features et choix du modèle
- ③ Analyse des résultats
 - Application des modèles sur la classe Mixtes
 - Comparaison des résultats des features pseudo-équivalentes
- ④ Conclusion et perspectives

Inférence du meilleur modèle sur la classe mixte

Distribution de la prédiction douce entre CCK et CHC



Plan

- ① Traitement des données
- ② Sélection des features et choix du modèle
- ③ Analyse des résultats
 - Application des modèles sur la classe Mixtes
 - Comparaison des résultats des features pseudo-équivalentes
- ④ Conclusion et perspectives

Récapitulatif des résultats

Modèle	Accuracy	ROC AUC	F1-Score	MCC
Modèle radiologue	0.985 ± 0.030	0.999 ± 0.002	0.983 ± 0.035	0.965 ± 0.069
Poids corrélation seuls	0.797 ± 0.095	0.878 ± 0.064	0.710 ± 0.111	0.475 ± 0.223
Poids corrélation + Lasso	0.830 ± 0.033	0.845 ± 0.064	0.744 ± 0.041	0.530 ± 0.092
Poids optimisés seuls	0.818 ± 0.081	0.848 ± 0.071	0.737 ± 0.103	0.523 ± 0.205
Poids optimisés + Lasso	0.853 ± 0.043	0.819 ± 0.067	0.777 ± 0.062	0.602 ± 0.118
Idem sur Multislice	0.835 ± 0.079	0.821 ± 0.102	0.780 ± 0.097	0.579 ± 0.178

Table – Comparaison des performances des modèles de pseudo-features

Plan

- 1 Traitement des données
- 2 Sélection des features et choix du modèle
- 3 Analyse des résultats
- 4 Conclusion et perspectives

Conclusion et perspectives

Bilan

- Radiomique ou Multislice ?
- Features à prendre en compte ?

Perspectives

- Faire un modèle de prédiction de la rechute voire de la létalité
- Tester notre modèle de classification sur d'autres données
- Entraîner un réseau de neurones convolutif sur des images 2D
- Utiliser des Transformers pour faire de l'extraction de données à partir des images 3D

Annexe : Méthode des deltas




Figure 21 - Méthode employée pour exploiter la cinétique de la tumeur

Annexe : Poids des features (1/2)

Variable Clinique	β_0 (Intercept)	Feature 1 (β_1)	Feature 2 (β_2)	Feature 3 (β_3)
APHE_heterogeneous	0.5502	Max2DDiamRow_ART (0.0476)	SurfVolRatio_TARD (-1.1866)	GLNonUniformity_PORT (0.138)
Bile_duct_dilatation	-2.9763	LALGLEmphasis_PORT (0.1497)	LDLGLEmphasis_TARD (-1.328)	LRLGLEmphasis_TARD (-0.7392)
Blood	-1.7333	Minimum_ART (-0.0004)	Busyness_ART (0.5862)	Busyness_PORT (0.2482)
Capsule	-0.1537	Sphericity_TARD (-0.0156)	Sphericity_PORT (0.4496)	Flatness_TARD (0.2937)
Diffusion_targetoid	-2.9102	InvVariance_PORT (-0.5273)	InvVariance_ART (-0.0515)	InvVariance_TARD (-0.0965)
Intratumoral_fat	-1.6201	ClusterShade_TARD (0.4594)	Skewness_delta_ART_PORT (-0.0)	ClusterShade_PORT (-0.2816)
LR-5	0.0307	Median_TARD (-0.0017)	Median_delta_TARD_ART (-0.0)	LDLGLEmphasis_PORT (0.3819)
LR-M	-0.9139	Busyness_PORT (-1.1298)	Median_TARD (-0.0001)	LALGLEmphasis_PORT (-0.2062)
Late_enhancement	-0.9865	LDHGLEmphasis_TARD (1.3069)	LRHGLEmphasis_TARD (-0.8183)	SALGLEmphasis_ART (-0.4796)

Annexe : Poids des features (2/2)

Variable Clinique	β_0 (Intercept)	Feature 1 (β_1)	Feature 2 (β_2)	Feature 3 (β_3)
Necrosis	-1.9009	SurfVolRatio_TARD (-0.7647)	SurfVolRatio_ART (-0.6294)	SurfVolRatio_PORT (-0.8075)
Nonperiph_washout	0.8754	LALGLEmphasis_PORT (0.5418)	Skewness_TARD (-0.0046)	10Percentile_delta_TARD_ART (0.0)
Portal_thrombosis	-2.4711	MajorAxisLength_ART (0.439)	Max3DDiameter_ART (0.2483)	Max2DDiamSlice_ART (0.628)
Rim_APHE	-0.6535	Median_TARD (0.0018)	Mean_TARD (0.0018)	LALGLEmphasis_PORT (-0.5064)
Satellite_nodule	-2.3116	Sphericity_ART (-0.8645)	Max3DDiameter_ART (0.3573)	Max3DDiameter_PORT (0.4995)
Shape	0.3232	Sphericity_ART (0.6368)	Sphericity_PORT (0.8196)	–
Size_mm	53.8309	SurfaceArea_TARD (13.1807)	SurfaceArea_PORT (-75.3571)	SurfaceArea_ART (100.2319)
nonrim_APHE	0.8634	Median_TARD (0.0001)	DepVariance_PORT (0.4161)	DepNonUnifNorm_PORT (-0.0693)

Annexe : comparaison données radiologiques VS radiomiques

Formulation des Hypothèses :

- $\mathcal{H}_0$: Absence de pouvoir discriminant entre la variable radiomique et le critère radiologique.
- $\mathcal{H}_1$: La caractéristique radiomique est significativement corrélée au critère.

AUC-ROC :

- probabilité qu'une caractéristique radiomique classe correctement deux patients tirés au hasard et présentant des modalités opposées du critère radiologique
- probabilité que, si l'on tire au hasard un patient avec capsule et un patient sans capsule, la valeur de la feature radiomique du premier soit supérieure (ou inférieure selon le sens de la corrélation) à celle du second